FACULTAD DE INGENIERÍA Y CIENCIAS APLICADAS

MAESTRÍA EN INTELIGENCIA ARTIFICIAL APLICADA

PROYECTO MIA

PROPUESTA DEL PROYECTO DE TITULACIÓN

Sistema Predictivo de Detección de Fallas en Infraestructura TI mediante IA

TUTOR:

Paredes Loor Raúl Vicente

AUTORES

Masache Narváez Valeria Estefanía

Guachamin Guevara Santiago David

Contenido – Propuesta del proyecto de titulación

1. Título del proyecto 3
2. Descripción del problema o necesidad 3
   2.1. Contexto general 3
   2.2. Descripción del problema o necesidad 3
   2.3. Causas principales 4
   2.4. Consecuencias del problema 4
3. Objetivo General 5
4. Objetivos específicos: 5
5. Justificación 6
6. Propuesta de solución 7
   6.1. Aternativa A: Sistema Predictivo Basado en Machine Learning Clásico 7
   6.2. Alternativa B: Sistema Predictivo con Deep Learning 9
   6.3. Criterios de comparación (ISO/IEC 25010) 10
7. Cronograma Tentativo 11
8. Referencias 11
9. Firmas de Responsabilidad 12

1. Título del proyecto

Modelo de IA para la Detección Temprana de Fallas en Servidores de Infraestructura en una empresa de Medicina Prepagada.

2. Descripción del problema o necesidad

2.1. Contexto general

La organización objeto de estudio pertenece al sector salud y se dedica a la gestión de seguros médicos. Su operación depende de manera crítica del funcionamiento continuo y estable de su infraestructura tecnológica.

Estos componentes tecnológicos soportan procesos clave del negocio, tales como la emisión de autorizaciones médicas, la gestión de siniestros, la atención a afiliados, la operación de plataformas internas, etc. Por tanto, la disponibilidad, estabilidad y desempeño de los servidores resultan fundamentales para garantizar la continuidad operativa y el cumplimiento de los niveles de servicio establecidos.

Actualmente, el departamento de tecnología realiza el monitoreo de la infraestructura mediante herramientas tradicionales basadas en umbrales predefinidos y en la revisión manual de alertas. Este enfoque permite identificar fallas una vez que estas ya se han producido, sin embargo, presenta limitaciones significativas para detectar de manera temprana comportamientos anómalos o patrones que puedan anticipar fallas inminentes en los servidores. Como consecuencia, la gestión de incidentes se mantiene en un enfoque predominantemente reactivo, lo que incrementa el riesgo de interrupciones no planificadas y afecta la eficiencia operativa de la organización.

2.2. Descripción del problema o necesidad

En la situación actual, los servidores experimentan de forma recurrente episodios de degradación en su rendimiento, asociados principalmente a incrementos repentinos en el uso de CPU, saturación de memoria, crecimiento no controlado del archivo de paginación y altos niveles de latencia en los discos. Estos eventos suelen ser identificados cuando los sistemas ya se encuentran en un estado crítico, lo que deriva en caídas del servicio, lentitud en las aplicaciones y una afectación directa tanto a los usuarios internos como a los externos.

La ausencia de un sistema de monitoreo predictivo y automatizado limita la capacidad de detectar con anticipación patrones de comportamiento anómalos en la infraestructura. Como resultado, la gestión de incidentes se realiza de manera tardía y reactiva, incrementando los tiempos de respuesta y el impacto operativo ante fallas no planificadas.

2.3. Causas principales

Mediante un análisis de causa–efecto, se identificaron los siguientes factores relevantes:

- Ausencia de mecanismos de análisis histórico que permitan identificar tendencias de saturación y degradación progresiva en los servidores.
- Dependencia de un enfoque de monitoreo reactivo, basado principalmente en alertas con umbrales fijos, lo que limita la detección temprana de comportamientos anómalos.
- Falta de integración entre las métricas de rendimiento, los eventos del sistema y los registros críticos, impidiendo una visión integral del estado de la infraestructura.
- Insuficiente correlación entre los principales indicadores de salud del servidor, como el uso de CPU, memoria y operaciones de entrada y salida, lo que dificulta la identificación oportuna de patrones anómalos.
- Crecimiento no controlado de procesos y servicios, cuya afectación solo se evidencia cuando la degradación del rendimiento ya es significativa.

2.4. Consecuencias del problema

Las fallas no detectadas anticipadamente han generado:

- **Interrupciones en servicios críticos**, afectando reembolsos, pagos, liquidaciones, etc.
- **Pérdidas operativas** estimadas en tiempos muertos por reinicios forzados de servidores.
- **Aumento de tickets de incidente**, incrementando la carga del equipo de plataformas.

- **Experiencia negativa de usuarios internos**, especialmente en áreas que dependen de sistemas transaccionales.
- **Riesgo de incumplimiento de SLA**, tanto internos como externos.

3. Objetivo General

Desarrollar un sistema inteligente de predicción de fallas en infraestructura tecnológica mediante aprendizaje automático, orientado a la detección temprana de anomalías y saturación de recursos, con el fin de garantizar la disponibilidad de los servicios críticos.

4. Objetivos específicos:

- Analizar, durante las dos primeras semanas del proyecto, la información histórica de los servidores, incluyendo métricas de rendimiento y registros de eventos, con el fin de comprender su comportamiento habitual e identificar patrones y variables clave que permitan anticipar posibles fallas mediante el uso de técnicas de inteligencia artificial.
- Diseñar, entre la tercera y la cuarta semana del proyecto, la arquitectura del sistema inteligente de detección predictiva de fallas, definiendo de manera clara los componentes necesarios para la recolección de datos, su procesamiento, el modelado, el almacenamiento y la visualización de la información, apoyándose en diagramas de contexto, modelos UML y flujos de datos.
- Desarrollar, entre la quinta y la octava semana del proyecto, los modelos de aprendizaje automático orientados a la detección de anomalías y a la predicción de fallas, utilizando algoritmos como Isolation Forest y modelos basados en series temporales, asegurando que el núcleo del sistema funcione de manera correcta y consistente.
- Integrar y evaluar, durante la novena y décima semana del proyecto, los modelos de inteligencia artificial con las herramientas de monitoreo y visualización, midiendo su desempeño mediante indicadores como precisión, recall y error de predicción, con el objetivo de verificar la confiabilidad del sistema propuesto.
- Implementar y validar, durante las dos últimas semanas del proyecto, el sistema inteligente en un entorno controlado de la organización, evaluando su impacto

a través de indicadores operativos, como la reducción del tiempo de detección de fallas y la disminución de incidentes críticos en la infraestructura.

5. Justificación

La continuidad operativa en las empresas del sector salud depende en gran medida de la estabilidad y disponibilidad de sus sistemas informáticos. Las plataformas responsables de procesos como la autorización médica, la gestión de afiliados, la emisión de coberturas y la evaluación de siniestros requieren infraestructuras tecnológicas altamente confiables, ya que cualquier interrupción puede afectar de forma directa el servicio ofrecido a afiliados y proveedores.

Diversos análisis de la industria destacan el crecimiento del uso de plataformas AIOps para mejorar la gestión proactiva de la infraestructura tecnológica. De acuerdo con Gartner (2023), la incorporación de inteligencia artificial en las operaciones de TI permite anticipar incidentes y optimizar la toma de decisiones operativas.

Actualmente, la organización presenta limitaciones en el monitoreo de su infraestructura tecnológica, debido a que los mecanismos utilizados se basan principalmente en umbrales fijos y alertas de carácter reactivo. Este enfoque permite identificar incidentes una vez que ya se han manifestado, pero resulta insuficiente para anticipar fallas inminentes o comportamientos anómalos en los servidores. Diversos estudios resaltan la necesidad de incorporar inteligencia artificial en las operaciones de tecnología de la información, especialmente en entornos complejos y altamente dinámicos. De acuerdo con Turban et al. (2021), la automatización inteligente constituye un pilar estratégico para mejorar la eficiencia operativa y la toma de decisiones en organizaciones digitales, mientras que investigaciones recientes sobre AIOps y detección de anomalías evidencian que el uso de modelos predictivos basados en aprendizaje automático permite transformar métricas operativas en información accionable para la gestión proactiva de la infraestructura (Chandola et al., 2021; Gartner, 2022).

En este contexto, la implementación de un sistema de detección temprana de fallas basado en inteligencia artificial permitirá fortalecer la resiliencia tecnológica de la organización. Dicho sistema facilitará la predicción de escenarios de saturación de recursos como: CPU, memoria, disco y la identificación de comportamientos anómalos asociados a procesos defectuosos, cargas inesperadas o fallos en la infraestructura.

Como resultado, se espera una reducción significativa de incidentes críticos, una mejora en la disponibilidad de los sistemas y una optimización del trabajo del personal de plataformas, que podrá adoptar un enfoque preventivo en lugar de reactivo.

Desde la perspectiva organizacional, el sistema propuesto aportará beneficios concretos, tales como la reducción del tiempo promedio de detección de fallas, la disminución del tiempo promedio de recuperación, la mejora del desempeño de servidores críticos y la continuidad de los servicios esenciales.

A nivel social, una mayor estabilidad de los sistemas tecnológicos contribuye indirectamente a una atención más ágil y eficiente, mejorando la experiencia de los usuarios de la aseguradora.

En el ámbito académico, el presente proyecto integra conceptos de series temporales, aprendizaje automático y arquitecturas de monitoreo en tiempo real. La viabilidad técnica se sustenta en el uso de herramientas de código abierto como Prometheus, Python, scikit-learn, PyTorch y Grafana, etc, así como en el apoyo del equipo de tecnología de la organización para la implementación y validación del sistema.

Finalmente, la propuesta resulta pertinente y original al integrar técnicas de inteligencia artificial en la gestión de infraestructura tecnológica, en un contexto donde la estabilidad y disponibilidad de los sistemas son factores críticos para la operación. Su implementación no solo permitirá mejorar la detección y prevención de fallas, sino que también sentará las bases para futuras mejoras, como la automatización de respuestas ante incidentes, la incorporación de mecanismos de escalamiento automático y la correlación avanzada de eventos para una gestión más eficiente de la infraestructura.

6. Propuesta de solución

6.1. Alternativa A: Sistema Predictivo Basado en Machine Learning Clásico

a. Descripción

Modelo basado en algoritmos como Isolation Forest, Random Forest y ightGBM para detectar anomalías y predecir saturación a corto plazo.

La automatización inteligente de las operaciones de TI, conocida como AIOps, combina técnicas de aprendizaje automático y análisis de grandes volúmenes de datos para identificar anomalías y reducir incidentes operativos (IBM, 2023).

b. Objetivo de la solución

Desarrollar un sistema inteligente que detecte anomalías y prediga degradaciones en servidores mediante modelos de aprendizaje automático clásicos, con el fin de anticipar incidentes y mejorar la disponibilidad de los servicios tecnológicos.

c. Alcance funcional

- Recolección continua de métricas de infraestructura (CPU, RAM, disco, I/O, red, pagefile).
- No se dispone de un histórico amplio de información al inicio del proyecto; sin embargo, durante la ejecución del proyecto se realizará la recolección continua y controlada de datos, con una frecuencia de muestreo de cada 60 minutos conforme nos permita la herramienta, se creará la construcción progresiva de un histórico de métricas de entre 3 y 4 meses, acorde con la duración del proyecto.
- Integración de eventos críticos del sistema para correlación básica.
- Detección de anomalías (comportamientos fuera de patrón).
- Predicción de saturación o degradación.
- Visualización en dashboard y generación de alertas a TI.

d. Arquitectura funcional

Cliente–Servidor + Web (híbrida operativa)

Servidor de monitoreo: Prometheus recolecta métricas desde los servidores Windows.

Servidor de IA (API): servicio en Python que consulta métricas, procesa features y ejecuta modelos ML.

Dashboard Web: Grafana consume Prometheus y el score generado (como métrica o endpoint)

e. **Tecnologías**
Prometheus, Python, scikit-learn, MLflow, Grafana.

f. **Modelo de contexto**

- Actores: Servidores, Prometheus, Sistema de IA, Personal de TI.
- Flujo alto nivel: VM, Prometheus, Modelo ML, Dashboard/Alertas.

6.2. Alternativa B: Sistema Predictivo con Deep Learning

a. **Descripción**

Uso de redes LSTM/GRU para series temporales que modelan comportamientos Complejos.**Objetivo de la solución**

Implementar un sistema de predicción avanzada que utilice redes neuronales para modelar patrones complejos en series temporales de métricas de infraestructura, permitiendo anticipar fallas mediante pronóstico multivariable y detección de anomalías con deep learning.

b. **Alcance funcional**

- Recolección continua de métricas de infraestructura y eventos del sistema.
- Normalización, limpieza y conformación de series temporales multivariadas.
- Entrenamiento de modelos Deep Learning para:

  Predicción de consumo de recursos (RAM, CPU, latencia disco, red)

  Detección de anomalías basadas en error de reconstrucción o desviación.
- Generación de score de riesgo y explicación básica del motivo de alerta (variables contribuyentes).
- Visualización en dashboard con predicción y alertas.

c. **Arquitectura propuesta**

Cliente–Servidor + Web + componente de IA (híbrida, mayor complejidad)

Servidor de monitoreo: Prometheus recolecta métricas desde Windows.

Data Store histórico: TimescaleDB/InfluxDB (para entrenamiento profundo se requiere histórico amplio).

Servidor de IA: servicio con PyTorch/TensorFlow para entrenamiento y predicción, expuesto como API.

Dashboard Web: Grafana + paneles de predicción y alertas.

d. Tecnologías

PyTorch/TensorFlow, Prometheus, ELK, Grafana.

e. Modelo de contexto

- Similar estructura, incorporando un módulo de predicción profunda.

6.3. Criterios de comparación (ISO/IEC 25010)

Se utilizó la norma ISO/IEC 25010 para evaluar objetivamente las alternativas propuestas, priorizando funcionalidad, fiabilidad y costo, lo que permitió seleccionar la solución más viable técnica y económicamente.

- **Funcionalidad:** La solución cumple con los requisitos definidos.
- **Fiabilidad:** Mide las capacidades del sistema.
- **Rendimiento:** Evalúa tiempo de respuesta del sistema, consumo de recursos, capacidad de análisis casi en tiempo real
- **Mantenibilidad:** Evalúa, tiempo de respuesta del sistema, consumo de recursos, capacidad de análisis casi en tiempo real
- **Seguridad:** Evalúa, protección de datos de monitoreo, control de accesos, aislamiento del sistema de IA
- **Costo:** Mide licencias, infraestructura adicional, complejidad de desarrollo, esfuerzo de capacitación

Valor	Significado
1	Muy deficiente
2	Deficiente
3	Aceptable
4	Bueno
5	Excelente

Criterio	Peso	Alternativa A	Alternativa B
Funcionalidad	20%	4	5
Fiabilidad	20%	4	4
Rendimiento	15%	4	5
Mantenibilidad	15%	5	3
Seguridad	10%	4	4
Costo	20%	4	2

Alternativa B es más potente, pero más compleja y costosa.

Alternativa A ofrece:

- Mejor mantenibilidad
- Menor costo
- Despliegue más simple
- Resultados suficientes para el objetivo del proyecto

Por lo tanto, se selecciona la Alternativa A como la opción más adecuada, al ser la que mejor se ajusta al contexto del proyecto y a las necesidades específicas de la organización.

La detección de anomalías se basa en la identificación de comportamientos que se desvían del patrón normal de operación de un sistema, permitiendo generar alertas tempranas ante posibles fallas o eventos de seguridad (ManageEngine, s. f.).

7. Cronograma Tentativo

Fase	Responsable(s)	Actividad principal	Entregables
Fase 1	Autores del proyecto / Área de TI	Análisis y levantamiento de información	Documento de análisis, listado de métricas
Fase 2	Autores del proyecto	Diseño de la solución	Diagramas de contexto, diseño técnico
Fase 3	Autores del proyecto	Preparación y preprocesamiento de datos	Dataset procesado y documentado
Fase 4	Autores del proyecto	Desarrollo de modelos de IA	Modelos entrenados, scripts documentados
Fase 5	Autores del proyecto / Área de TI	Integración y evaluación	Resultados de evaluación, métricas
Fase 6	Autores del proyecto / Área de TI	Implementación y validación final	Sistema funcional, informe final
Fase 7	Autores del proyecto	Defensa del proyecto	Prototipo funcional

8. Referencias

- Turban, E., Pollard, C., & Wood, G. (2021). *Information technology for management: Driving digital transformation to increase local and global performance, growth and sustainability (12th ed.).* Wiley.
- Chandola, V., Banerjee, A., & Kumar, V. (2021). *Anomaly detection: A survey. ACM Computing Surveys, 54(2), 1–38*. https://doi.org/10.1145/3439950

- Gartner. (2023). *Strategic predictions for 2026*. https://www.gartner.com/en/articles/strategic-predictions-for-2026
- ISO/IEC. (2011). *ISO/IEC 25010: Systems and software engineering—Systems and software quality requirements and evaluation (SQuaRE)—System and software quality models*. International Organization for Standardization.
- Gartner. (2023). Strategic predictions for 2026: AI and AIOps. https://www.gartner.com/en/articles/strategic-predictions-for-2026
- IBM. (2023). What is AIOps? Artificial intelligence for IT operations. https://www.ibm.com/topics/aiops
- ManageEngine. (s. f.). ¿Qué es la detección de anomalías? https://www.manageengine.com/latam/log-management/ciberseguridad/que-es-la-deteccion-de-anomalias.html

9. Firmas de Responsabilidad

TUTOR: Paredes Loor Raúl Vicente **FECHA (DD/MM/AAAA):** 19/01/2026

AUTOR 1: Masache Narvaez Valeria Estefania **FECHA (DD/MM/AAAA):** 16/12/2025

AUTOR 2: Guachamin Guevara Santiago David **FECHA (DD/MM/AAAA):** 16/12/2025

Lista de Verificación para la calificación del primer entregable de TITA1

A continuación, se muestra una Lista de Verificación (Checklist) que permita evaluar si el documento de Propuesta del Proyecto MIA cumple con los parámetros definidos.

Criterio de Evaluación	Cumple / No Cumple	Nota
1. Título del Proyecto – Claridad, especificidad, relación directa con la solución.	☐ Cumple ☐ No Cumple	1
2. Descripción del Problema o Necesidad – Incluye contexto general, situación actual, causas y consecuencias de manera clara.	☐ Cumple ☐ No Cumple	2.5
3. Objetivo General y específico – Redactado de forma precisa, con verbo en infinitivo, y os objetivos específicos alineado a SMART, entre 25 y 40 palabras.	☐ Cumple ☐ No Cumple	2
4. Justificación – Explica relevancia, importancia, impacto (social/tecnológico/académico), pertinencia, viabilidad y originalidad. Extensión adecuada (300–700 palabras).	☐ Cumple ☐ No Cumple	2
5. Propuesta de Solución – Presenta al menos 2 alternativas con modelo de contexto. Incluye criterios comparativos (ISO/IEC 25010 u otros), indicadores, viabilidad técnica/operativa.	☐ Cumple ☐ No Cumple	2
6. Referencias – Referenciada según Normas APA 7. Al menos 80% de fuentes de los últimos 5 años. Incluye teoría básica si aplica.	☐ Cumple ☐ No Cumple	0.5
	Total	10

NOTA IMPORTANTE: Es necesario que, para la firma del documento, el tutor y los alumnos estén de acuerdo con la nota establecida y el cumplimiento o no de esta; luego, el comité de titulación en la fecha y hora correspondiente ratificará o pedirá la modificación de la nota en el caso de existir diferencias de puntuación en la lista de verificación distinta a la establecida por el tutor.